

课程准备知识

殷东生

dyin@math.tsinghua.edu.cn

清华大学数学科学系

2018年秋季学期

定义 (线性空间:linear space)

设 \mathbb{P} 是一个数域, 一般取 $\mathbb{P} = \mathbb{R}, \mathbb{C}$, V 是一个非空集合, 在 V 上定义两种运算

- **加法:** $\forall u, v \in V$, 有 V 中唯一的元素 $(u + v)$ 与之对应, 且

$$u + v = v + u, \quad \forall u, v \in V,$$

$$u + (v + w) = (u + v) + w, \quad \forall u, v, w \in V,$$

且 V 中有唯一的零元素 θ 使得

$$u + \theta = u, \quad \forall u \in V.$$

对每一个 $u \in V$ 有唯一的负元素 $-u$ 与之对应, 使得

$$u + (-u) = \theta.$$

定义 (线性空间)

- **数乘**: $\forall \alpha \in \mathbb{P}, u \in V$, 有 V 中的唯一的元素 αu 与之对应, 满足

$$1u = u, \forall u \in V,$$

$$\alpha(\beta u) = (\alpha\beta)u, \forall \alpha, \beta \in \mathbb{P}, u \in V,$$

$$\alpha(u + v) = \alpha u + \alpha v,$$

$$(\alpha + \beta)u = \alpha u + \beta u, \forall \alpha, \beta \in \mathbb{P}, u \in V,$$

称 V 为 **数域 \mathbb{P} 上的线性空间 (数域 \mathbb{P} 上的向量空间)**。

注记 (子空间 subspace)

若线性空间 V 的一个子集 W 按照 V 的加法和数乘也是一个线性空间, 则称 W 是 V 的 **线性子空间**。

例 (\mathbb{R}^n 和 \mathbb{C}^n)

\mathbb{R}^n 是 n 维实向量的全体, 按照向量的加法以及实数与向量的乘法构成了实数域 \mathbb{R} 上的线性空间。通常, 向量是指列向量, 亦即 $\mathbf{x} \in \mathbb{R}^n$, 则 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$, 其中 $x_1, x_2, \dots, x_n \in \mathbb{R}$ 。 \mathbb{R}^n 中的零元素就是零向量 $\mathbf{0} = (0, 0, \dots, 0)^T$ 。

类似的可定义 \mathbb{C}^n 。

例 (连续函数空间)

设 $[a, b]$ 为闭区间, 定义

$$C[a, b] := \{f | f \text{ 在 } [a, b] \text{ 上连续}\}$$

则 $C[a, b]$ 是一个线性空间。

例 (矩阵空间 $\mathbb{R}^{m \times n}$ 与 $\mathbb{C}^{m \times n}$)

$\mathbb{R}^{m \times n}$ 是所有 m 行 n 列实元素矩阵的全体

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix},$$

按矩阵的加法以及实数与矩阵的乘法构成了 \mathbb{R} 上的线性空间。它的零元素是 m 行 n 列的零矩阵，其所有元素均为零。同理有 $\mathbb{C}^{m \times n}$ 。

例

多项式空间

$$P_N := \{p(x) | p(x) = a_0 + a_1x + \cdots + a_Nx^N, a_i \in R(C)\}$$

线性独立

定义 (线性无关 linearly independent)

设 (V, \mathbb{P}) 是一个线性空间, $x_i \in V, i = 1, 2, \dots, n$, 若存在 $a_i \in \mathbb{P}, i = 1, 2, \dots, n, \sum_{i=1}^n |a_i| > 0$, 使得

$$a_1x_1 + a_2x_2 + \dots + a_nx_n = 0,$$

则称 $\{x_i\}_{i=1}^n$ 是线性相关的, 反之, 则称线性无关的。

- 1 在 P_N 中, $\{1, x, \dots, x^N\}$ 是线性无关的。
- 2 在 $C[-\pi, \pi]$ 中, $\{1, \cos x, \sin x, \dots, \cos nx, \sin nx\}$ 是线性无关的。

基和维数

若 $\{x_i\}_{i=1}^n$ 线性无关, 且 $\forall x \in V$, 有 $\{a_i\}_{i=1}^n$ 使得

$$x = a_1x_1 + a_2x_2 \cdots + a_nx_n,$$

则 $\{x_i\}_{i=1}^n$ 构成 S 的一组基(basis), 空间的维数为 n 。

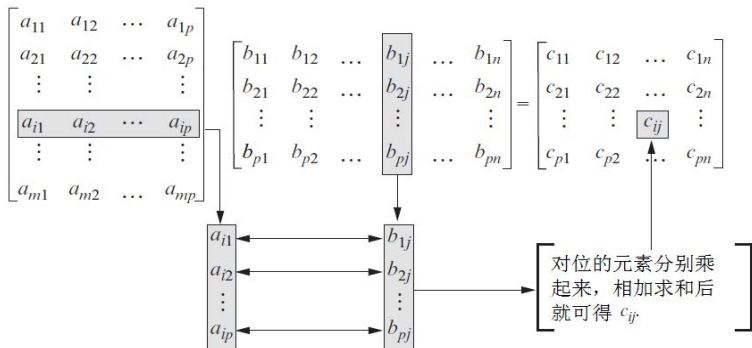
注记

线性空间的维数与基的选取无关, 它是空间的内在性质。

- ① P_N 中 $\{1, x, \cdots, x^N\}$ 是一组基。 $\dim P_N = N + 1$
- ② $C[a, b]$ 中 $\forall N, \{1, x, \cdots, x^N\}$ 是线性无关的, $\dim C[a, b] = +\infty$ 。

存在 $\mathbb{P}^{m \times p} \times \mathbb{P}^{p \times n} \rightarrow \mathbb{P}^{m \times n}$ 的一个运算, 称为 **矩阵乘法**

$$AB = C, c_{ij} = \sum_{1 \leq k \leq p} a_{ik} b_{kj}$$



Q: 矩阵乘法的计算量?

Matlab 求迹的命令为 trace

定义 (迹)

设 $A = (a_{ij})_{i,j=1}^n \in \mathbb{C}^{n \times n}$,
矩阵 A 的迹(trace) 是其所有
对角元元素之和。

$$\text{trace}(A) = \sum_{i=1}^n a_{ii}$$

定理

若 $A \in \mathbb{C}^{n \times n}$, $B \in \mathbb{C}^{n \times n}$,
则

$$\text{trace}(AB) = \text{trace}(BA).$$

```
>> A = [1 5 1; 2 -1 6; 1 0 3]
```

```
A =  
     1     5     1  
     2    -1     6  
     1     0     3
```

```
>> B = [2 3 0; 3 -1 7; 4 8 9]
```

```
B =  
     2     3     0  
     3    -1     7  
     4     8     9
```

```
>> trace(A + B)
```

```
ans =  
    13
```

```
>> 7*trace(A + B)
```

```
ans =  
    91
```

定义 (非奇异矩阵 nonsingular matrix)

矩阵 $A \in \mathbb{R}^{n \times n}$ 称为非奇异的或可逆的 (invertible), 若存在一个矩阵 $B \in \mathbb{R}^{n \times n}$ 使得

$$AB = BA = I.$$

其中 B 称为 A 的逆矩阵 (inverse)。若 A 的逆矩阵不存在, 则称其是奇异的 (singular)。

注记

若 $A_1, A_2, \dots, A_m \in \mathbb{R}^{n \times n}$ 都非奇异, 则 $A_1 A_2 \cdots A_m$ 亦是非奇异的, 且

$$(A_1 A_2 \cdots A_m)^{-1} = A_m^{-1} \cdots A_2^{-1} A_1^{-1}.$$

定理 (线性方程组的可解性)

若矩阵 $A \in \mathbb{R}^{n \times n}$ 可逆, 则方程组 $Ax = b$ 有唯一解 $x = A^{-1}b$ 。

注记

$A \in \mathbb{R}^{n \times n}$ 是非奇异的 \iff 齐次方程 $Ax = 0$ 只有 0 解, 亦称为平凡解。

Matlab 求逆矩阵的命令为 $\text{inv}(A)$ 。

```
>> format rational;
>> A = [1 3 -1; 4 1 6; 0 2 3]
A =
1 3 -1
4 1 6
0 2 3

>> A_inv = inv(A)
A_inv =
9/53 11/53 -19/53
12/53 -3/53 10/53
-8/53 2/53 11/53

>> B = [1 4 0; 3 5 1; 2 -7 8]
B =
1 4 0
3 5 1
2 -7 8

>> B_inv = inv(B)
B_inv =
-47/41 32/41 -4/41
22/41 -8/41 1/41
31/41 -15/41 7/41

>> inv(A*B)
ans =
-7/2173 -621/2173 1169/2173
94/2173 268/2173 -487/2173
43/2173 400/2173 -662/2173

>> B_inv * A_inv
ans =
-7/2173 -621/2173 1169/2173
94/2173 268/2173 -487/2173
43/2173 400/2173 -662/2173
```

定理

- 1 A 非奇异当且仅当 $\det A \neq 0$;
- 2 A 奇异当且仅当 $\det A = 0$;
- 3 齐次方程 $Ax = 0$ 有非平凡解当且仅当 $\det A = 0$ 。

Matlab 求行列式的命令为 $\det(A)$ ，而求方程组 $Ax = b$ 的命令为 “\”，用 $A \backslash b$ 来得到 x 。

```
>> A = [1 6 25;16 32 19;56 53 5];
>> det(A)

ans =
    -18543

>> A\[1 2 5]'

ans =
    0.0910
   -0.0053
    0.0376

>> B = [1 3 2;5 14 7;2 5 1];
>> det(B)

ans =
   -3.3307e-015

>> size(null(B),2) % compute the nullity of B

ans =
     1

>> B\[1 2 5]'
Warning: Matrix is close to singular or badly scaled.
Results may be inaccurate. RCOND = 4.587698e-018.

ans =
   1.0e+016 *
    1.2610
   -0.5404
    0.1801
```

定义 (矩阵的转置)

设 $A \in \mathbb{R}^{m \times n}$, 它的转置 (transpose) A^T 可通过交换 A 的行和列得到, 亦即

$$A = [a_{ij}] \implies (A^T)_{ij} = a_{ji}, \quad A^T \in \mathbb{R}^{n \times m}$$

例

$$A = \begin{pmatrix} 1 & 9 & 0 \\ 3 & 7 & 15 \\ 4 & 8 & 1 \\ -7 & 12 & 3 \end{pmatrix} \quad A^T = \begin{pmatrix} 1 & 3 & 4 & -7 \\ 9 & 7 & 8 & 12 \\ 0 & 15 & 1 & 3 \end{pmatrix}$$

$$(A^T)^T = A, \quad (AB)^T = B^T A^T, \quad (A^T)^{-1} = (A^{-1})^T$$

Matlab 求矩阵的转置命令为 '

定义 (对称矩阵)

矩阵 $A \in \mathbb{R}^{n \times n}$ 称为**对称**

的(*symmetric*)若 $A^T = A$ 。即

$$a_{ij} = a_{ji}, \forall 1 \leq i, j \leq n.$$

亦即交换 A 的行列, A 不变。

推论

若 $A \in \mathbb{R}^{m \times n}$, 则 $A^T A \in \mathbb{R}^{n \times n}$ 是对称矩阵。

```
>> A = [1 8 -1; 3 -9 15; -1 5 3]
```

```
A =  
     1     8    -1  
     3    -9    15  
    -1     5     3
```

```
>> A_TA = A'*A
```

```
A_TA =  
    11    -24    41  
   -24    170   -128  
    41   -128    235
```

```
>> A_TA - A_TA'
```

```
ans =  
     0     0     0  
     0     0     0  
     0     0     0
```

对于方阵 $A \in \mathbb{C}^{n \times n}$, 若有 $\lambda \in \mathbb{C}$ 和非零向量 $\mathbf{x} \in \mathbb{C}^n$, 使得

$$A\mathbf{x} = \lambda\mathbf{x}$$

则称 \mathbf{x} 为 **特征值**(eigenvalue) λ 对应的 **特征向量**(eigenvector)。

定义 (特征值)

$A \in \mathbb{R}^{n \times n}$, 多项式 $p(\lambda) = \det(\lambda I - A)$ 称为 A 的 **特征多项式**(characteristic polynomial), 方程 $p(\lambda) = 0$ 称为 **特征方程**(characteristic equation), 若 λ 是 p 的根, 则 λ 是 A 的特征值, 若 \mathbf{v} 是满足 $A\mathbf{v} = \lambda\mathbf{v}$ 的非零列向量, 则 \mathbf{v} 是 A 的一个特征向量。

问题

上述特征值的定义是否可以用来数值求解特征值?

定义 (谱)

对任一 $A \in \mathbb{C}^{n \times n}$, 其有 n 个特征值 (可以相同)。全体特征值的集合称为 A 的 **谱** (*spectrum*), 记作 $\sigma(A)$, 即

$$\sigma(A) \stackrel{\text{def}}{=} \{\lambda_1, \dots, \lambda_n\}$$

$$\rho(A) \stackrel{\text{def}}{=} \max_{\lambda \in \sigma(A)} |\lambda|$$

称为 A 的 **谱半径** (*spectrum radius*)。

$$\text{trace}(A) = \sum_{1 \leq i \leq n} \lambda_i,$$

$$\det A = \lambda_1 \lambda_2 \cdots \lambda_n$$

定义 (可对角化)

设 $A \in \mathbb{P}^{n \times n}$, 若存在非奇异阵 $P \in \mathbb{P}^{n \times n}$, 使得

$$D = P^{-1}AP$$

为对角阵, 则称 A 可对角化 (*diagonalizable*)。 A 可对角化的充要条件是它有 n 个线性无关的特征向量。

若 A 是实对称矩阵, 则 A 的特征值都是实数, 可以对角化。

定理

矩阵 $A \in \mathbb{R}^{n \times n}$ 的不同特征值对应的特征向量是线性无关的。若 A 有 n 个不同的特征值, 则 A 可对角化。

若 A 具有重特征值, 即特征方程有重根, 则

$$\det(\lambda I - A) = (\lambda - \lambda_1)^{n_1}(\lambda - \lambda_2)^{n_2} \cdots (\lambda - \lambda_s)^{n_s}, \lambda_i \neq \lambda_j, \text{ if } i \neq j,$$

亦即 λ_i 是特征方程的 n_i 重根。 n_i 称为特征值 λ_i 的代数重数。

$$n_1 + n_2 + \cdots + n_s = n, \quad n_i \geq 1, 1 \leq i \leq s.$$

设 λ_i 对应的最大线性无关特征向量的个数为 m_i , 则 m_i 就是齐次方程组 $(\lambda_i I - A)\mathbf{x} = 0$ 的基础解系所包含最大线性无关解的个数, m_i 称为特征值 λ_i 的几何重数。

一般地

$$m_i \leq n_i, \quad i = 1, 2, \cdots, s.$$

定理

设 A 具有重特征值，则 A 可对角化的充要条件为每个特征值的几何重数和代数重数相等。

Matlab 中求特征值和特征向量的命令为 `eig(A)`，若要得到特征值和其对应的特征向量可用

`>> [V D]=eig(A)`

D 是由特征值组成的对角阵， V 的列向量是特征值对应的特征向量。如求 B 的特征对。

$$B = \begin{pmatrix} 1 & 6 & 3 \\ -1 & 4 & 9 \\ 12 & 35 & 1 \end{pmatrix}$$

```
>> [V E] = eig(B)
V =
    0.0118    0.9119    0.2500
    0.4211   -0.3220    0.4278
   -0.9069    0.2545    0.8686
E =
  -15.4092         0         0
         0   -0.2812         0
         0         0   21.6905
>> eig(B)
ans =
  -15.4092
   -0.2812
   21.6905
```

定理 (Jordan标准型)

任一复方阵可以通过相似变换化为 *Jordan* 标准型 J ,

$$P^{-1}AP = J = \begin{pmatrix} J_1 & & & \\ & J_2 & & \\ & & \ddots & \\ & & & J_p \end{pmatrix}$$

每个 J_i 对应一个特征值 λ_i , 它是 r_i 个小块组成的块对角阵

$$J_i = \begin{pmatrix} J_{i1} & & & \\ & J_{i2} & & \\ & & \ddots & \\ & & & J_{ir_i} \end{pmatrix}, J_{ik} = \begin{pmatrix} \lambda_i & 1 & & \\ & \ddots & \ddots & \\ & & \lambda_i & 1 \\ & & & \lambda_i \end{pmatrix}$$

内积空间

定义 (内积(inner product))

设 V 是数域 \mathbb{P} 上的线性空间, 内积 $(\cdot, \cdot) : V \times V \rightarrow \mathbb{P}$, 对于 $\forall u, v \in V, \exists ! (u, v) \in \mathbb{P}$ 与之对应, 且有:

- ① $(u + v, w) = (u, w) + (v, w), \quad \forall u, v, w \in V;$
- ② $(\alpha u, v) = \alpha(u, v), \quad \forall u, v \in V, \alpha \in \mathbb{P};$
- ③ $(u, v) = \overline{(v, u)}, \quad \forall u, v \in V;$
- ④ $(u, u) \geq 0, \quad \forall u \in V, \text{ 且 } (u, u) = 0 \Leftrightarrow u = \theta.$

则称 (u, v) 是 u 和 v 的**内积**, 定义了内积的空间称为**内积空间**。

例 (\mathbb{R}^n 和 \mathbb{C}^n 的内积)

$\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 则内积 (\mathbf{x}, \mathbf{y}) 定义为

$$(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n x_i y_i = \mathbf{y}^T \mathbf{x}.$$

若 $\mathbf{x}, \mathbf{y} \in \mathbb{C}^n$, 则内积定义为

$$(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n x_i \bar{y}_i = \bar{\mathbf{y}}^T \mathbf{x}.$$

如果给定 $\omega_i \in \mathbb{R}, \omega_i > 0, 1 \leq i \leq n$ (权系数), 可定义一种带权内积:

$$(\mathbf{x}, \mathbf{y})_{\omega} = \sum_{i=1}^n \omega_i x_i y_i$$

正交向量

定义 (正交(orthogonal))

若向量 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ 满足 $(\mathbf{x}, \mathbf{y}) = 0$, 则称它们是**正交的**。两个向量的集合 X 和 Y , 若每个 $\mathbf{x} \in X$ 都和每个 $\mathbf{y} \in Y$ 正交, 则称 X 与 Y 正交。

S 是非零向量的集合, 若 $\forall \mathbf{x}, \mathbf{y} \in S, \mathbf{x} \neq \mathbf{y} \Rightarrow (\mathbf{x}, \mathbf{y}) = 0$, 则其为正交集

定理

正交集 S 中的向量是线性无关的。

推论

若正交集 $S \subseteq \mathbb{R}^n$ 有 n 个向量, 则它是 \mathbb{R}^n 的一组基。

正交矩阵

定义 (正交矩阵(orthogonal matrix))

设 $A \in \mathbb{R}^{n \times n}$, 若满足

$$A^T A = I,$$

则称 A 为 **正交矩阵**。

正交矩阵有如下的性质:

- ① A 不同的列向量相互正交, 且各列向量的2-范数为1。
- ② $A^{-1} = A^T$, 且 A^T 也是正交矩阵。
- ③ $|\det A| = 1$ 。
- ④ 若 A 和 B 是同阶的正交矩阵, 则 AB 和 BA 都是正交矩阵。

定义 (L^2 内积)

设 $f(x), g(x) \in C[a, b]$, 则它们的 L^2 内积为

$$(f, g) = \int_a^b f(x)g(x)dx.$$

定义 (权函数(weight function))

若定在 $[a, b]$ 上的可积函数 $\rho(x)$ 满足

- ① $\rho(x) \geq 0, \forall x \in [a, b]$;
- ② 在 $[a, b]$ 的任一子区间上 $\rho(x)$ 不恒为零。

称 $\rho(x)$ 为 $[a, b]$ 上的一个权函数。

利用权函数可定义带权 L^2 内积:

$$(f, g)_\rho = \int_a^b \rho(x)f(x)g(x)dx$$

定理 (Cauchy-Schwarz不等式)

设 V 是一个内积空间, 则对任一的 u, v 有

$$|(u, v)|^2 \leq (u, u)(v, v),$$

等号当且仅当 u, v 线性相关时成立。

数学家简介 (柯西(Cauchy))

柯西(Cauchy, 1789—1857)是法国数学家、物理学家、天文学家。柯西在数学上的最大贡献是在微积分中引进了极限概念，并以极限为基础建立了逻辑清晰的分析体系。复变函数的微积分理论就是由他创立的。1821年柯西提出极限定义的方法，把极限过程用不等式来刻画，后经魏尔斯特拉斯改进，成为现在所说的柯西极限定义或叫 $\epsilon - \delta$ 定义。当今所有微积分的教科书都还沿用着柯西等人关于极限、连续、导数、收敛等概念的定义。柯西对定积分作了最系统的开创性工作，他把定积分定义为和的“极限”。在定积分运算之前，强调必须确立积分的存在性。他利用中值定理首先严格证明了微积分基本定理。使数学分析的基本概念得到严格的论述。把微积分及其推广从对几何概念、运动和直观了解的完全依赖中解放出来，并使微积分发展成现代数学最基础最庞大的数学学科。



Faà di Bruno \mapsto
Peano \mapsto Russell

Gram-Schmidt正交化方法

若 $\{u_1, u_2, \dots, u_n\}$ 是内积空间 V 中的一个线性无关元素系列, 则

$$\begin{cases} v_1 = u_1, \\ v_i = u_i - \sum_{k=1}^{i-1} \frac{(u_i, v_k)}{(v_k, v_k)} v_k, \quad i = 2, 3, \dots \end{cases}$$

生成 V 中的一个正交序列 $\{v_1, v_2, \dots, v_n\}$ 是 $\text{span}\{u_1, u_2, \dots, u_n\}$ 的一组基。

注记

Gram-Schmidt 正交化以丹麦数学家 *Gram* 和德国数学家 *Schmidt* 的名字命名, 但是最先由 *Laplace* 和 *Cauchy* 给出。

数学家简介 (Pierre-Simon Laplace)

拉普拉斯(1749—1827)是法国分析学家、概率论学家和物理学家，法国科学院院士。是天体力学的主要奠基人、天体演化学的创立者之一，还是分析概率论的创始人，是应用数学的先驱。他发表的天文学、数学和物理学的论文有270多篇，专著合计有4006多页。其中最有代表性的专著有《天体力学》、《宇宙体系论》（中译本1978年版）和《概率分析理论》（1812）。



Laplace 方程 $-\Delta u = 0;$

Laplace 变换 $F[s] = \mathcal{L}[f(t)] = \int_0^{+\infty} f(t)e^{-st} dt.$

若要求归一化即 $\|q_i\|_2 = 1, 1 \leq i \leq n$, 则由Gram-Schmidt 正交化可得QR 分解。 设

$$u_1 = \begin{pmatrix} 1 \\ -1 \\ 1 \\ 1 \end{pmatrix}, \quad u_2 = \begin{pmatrix} 2 \\ 0 \\ 0 \\ 2 \end{pmatrix}$$

❶ 归一化: $q_1 = \frac{1}{2}(1, -1, 1, 1)^T$ 。

❷ 计算投影: $(u_2, q_1) = 2$, 接着

$$\hat{q} = u_2 - (u_2, q_1)q_1 = \begin{pmatrix} 2 \\ 0 \\ 0 \\ 2 \end{pmatrix} - 2 \times \frac{1}{2} \begin{pmatrix} 1 \\ -1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ -1 \\ 1 \end{pmatrix}$$

❸ 归一化: $q_2 = \frac{1}{2}(1, 1, -1, 1)^T$ 。

经典的Gram-Schmidt正变化

算法 (Classical Gram-Schmidt)

- 1 *compute* $r_{11} := \|\mathbf{u}_1\|_2$. *If* $r_{11} = 0$ *stop*, *else compute* $\mathbf{q}_1 := \mathbf{u}_1/r_{11}$
- 2 *For* $j = 2, \dots, n$. *Do*
- 3 *Compute* $r_{ij} := (\mathbf{u}_j, \mathbf{q}_i)$ *for* $i = 1, 2, \dots, j-1$
- 4 $\hat{\mathbf{q}} := \mathbf{u}_j - \sum_{i=1}^{j-1} r_{ij} \mathbf{q}_i$
- 5 $r_{jj} := \|\hat{\mathbf{q}}\|_2$
- 6 *If* $r_{jj} = 0$ *then stop*, *else* $\mathbf{q}_j := \hat{\mathbf{q}}/r_{jj}$
- 7 *EndDo*

若 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 线性无关, 则算法 n 步完成。

定义矩阵 R 的元素为

$$r_{ij} = \begin{cases} (\mathbf{u}_j, \mathbf{q}_i), & i < j \\ \|\hat{\mathbf{q}}\|_2, & i = j \\ 0, & i > j \end{cases}$$

$$\Rightarrow \mathbf{u}_j = r_{1j}\mathbf{q}_1 + r_{2j}\mathbf{q}_2 + \cdots + r_{jj}\mathbf{q}_j, \quad 1 \leq j \leq n.$$

令 $U = [\mathbf{u}_1, \mathbf{u}_2, \cdots, \mathbf{u}_n]$, $Q = [\mathbf{q}_1, \mathbf{q}_2, \cdots, \mathbf{q}_n]$, 且令 $R \in \mathbb{R}^{n \times n}$ 是上面定义的矩阵的上三角部分

$$R = \{r_{ij}\}_{i,j=1}^n.$$

则有 U 的QR分解(QR factorization)

$$U = QR$$

若 $U \in \mathbb{R}^{m \times n}$ 列满秩, 则有

$$U = Q * R$$

Original matrix

Q is orthogonal ($Q^T Q = I$)

R is upper triangular

Matlab 的 Classical Gram-Schmidt

算法的程序和计算结果:

```
function [Q R]=cgs(A)
[m,n]=size(A);Q=zeros(m,n);R=zeros(n,m) %以使矩阵具有正确的大小。
for j=1:n %Gram-Schmidt正交化
v=A(:,j); %v初始化为A的第j列
for i=1:j-1
R(i,j)=Q(:,i)'\*A(:,j); %为提高精确度用A(:,j)代替v
v=v-R(i,j)*Q(:,i); %减去投影
end %v现在和q1,...,qj 正交
R(j,j)=norm(v);
Q(:,j)=v/R(j,j); %将v规范化使之成为单位向量qj
end
```

$$A = \begin{bmatrix} 1 & 1 & 1 \\ \epsilon & 0 & 0 \\ 0 & \epsilon & 0 \\ 0 & 0 & \epsilon \end{bmatrix}, \quad \epsilon = 10^{-8}$$

```
>> epsilon = 1.0e-8;
A = [1 1 1;epsilon 0 0;0 epsilon 0;0 0 epsilon];
>> [Q R]=cgs(A)
```

Q =

1.0000	0	0
0.0000	-0.7071	-0.7071
0	0.7071	0
0	0	0.7071

R =

1.0000	1.0000	1.0000	0
0	0.0000	0	0
0	0	0.0000	0

```
>> Q'\*Q
```

ans =

1.0000	-0.0000	-0.0000
-0.0000	1.0000	0.5000
-0.0000	0.5000	1.0000

改进的方法(modified Gram-Schmidt MGS)算法

算法 (MGS)

- 1 Define $r_{11} := \|\mathbf{u}_1\|_2$. If $r_{11} = 0$ Stop, else $\mathbf{q}_1 := \mathbf{u}_1/r_{11}$
- 2 For $j = 2, \dots, n$, Do
- 3 Define $\hat{\mathbf{q}} := \mathbf{u}_j$
- 4 For $i = 1, \dots, j-1$, Do
- 5 $r_{ij} := (\hat{\mathbf{q}}, \mathbf{q}_i)$
- 6 $\hat{\mathbf{q}} := \hat{\mathbf{q}} - r_{ij}\mathbf{q}_i$
- 7 EndDo
- 8 Compute $r_{jj} := \|\hat{\mathbf{q}}\|_2$
- 9 If $r_{jj} = 0$ then Stop, else $\mathbf{q}_j := \hat{\mathbf{q}}/r_{jj}$
- 10 EndDo

Matlab 的修正的Gram-Schmidt 算

法的程序和计算结果:

```
% Modified Gram-Schmidt method
function [Q,R] = mgs(A)
[m,n]=size(A);
Q=zeros(m,n); %矩阵的行和列
Q(1:m,1) = A(1:m,1);
R=zeros(n); R(1,1)=1;
for k = 1:n
    R(k,k) = norm (A(1:m,k));
    Q(1:m,k) = A(1:m,k)/R(k,k); %对本次得到的正交向量进行归一化
    for j=k+1:n
        R(k,j) = Q(1:m,k)' * A(1:m,j);
        A(1:m,j) = A(1:m,j) - Q(1:m,k)*R(k,j) %对剩余向量进行修正
    end
end
```

$$A = \begin{bmatrix} 1 & 1 & 1 \\ \epsilon & 0 & 0 \\ 0 & \epsilon & 0 \\ 0 & 0 & \epsilon \end{bmatrix}, \quad \epsilon = 10^{-8}$$

```
>> epsilon = 1.0e-8;
A = [1 1 1;epsilon 0 0;0 epsilon 0;0 0 epsilon];
>> [Q R]=mgs(A)
```

Q =

1.0000	0	0
0.0000	-0.7071	-0.4082
0	0.7071	-0.4082
0	0	0.8165

R =

1.0000	1.0000	1.0000
0	0.0000	0.0000
0	0	0.0000

```
>> Q'*Q
```

ans =

1.0000	-0.0000	-0.0000
-0.0000	1.0000	0.0000
-0.0000	0.0000	1.0000

范数与线性赋范空间

定义 (范数与线性赋范空间)

设 V 是数域 \mathbb{P} 上的线性空间, 定义 $\|\cdot\|: u \rightarrow \|u\|$ 是 V 到 \mathbb{R} 的一个线性映射, 满足

- ① 正定性(positivity): $\|u\| \geq 0, \forall u \in V$; 且 $\|u\| = 0 \Leftrightarrow u = \theta$ 。
- ② 齐次性(scaling): $\|\alpha u\| = |\alpha| \|u\|, \forall u \in V, \alpha \in \mathbb{P}$ 。
- ③ 三角不等式(triangle inequality): $\|u + v\| \leq \|u\| + \|v\|, \forall u, v \in V$ 。

称 $\|\cdot\|$ 为 V 的范数(模)(norm), 定义了范数的线性空间称为赋范线性空间。

定义 (距离)

设 X 是任一非空集合, X 中的任意两点 x, y 有 $d(x, y) \in \mathbb{R}$ 与之对应且满足:

- ① 非负性: $d(x, y) \geq 0$, 且 $d(x, y) = 0$ 当且仅当 $x = y$;
- ② 对称性: $d(x, y) = d(y, x)$;
- ③ 三角不等式: $d(x, y) \leq d(x, z) + d(z, y)$ 。

称 $d(x, y)$ 为 X 上的一个距离, 定义了距离 d 的集合 X 称为一个距离空间 (X, d) , 简记为 X 。

有了范数就可以定义距离, 设 V 是赋范空间, 则 $u, v \in V$ 的距离为

$$d(u, v) = \|u - v\|.$$


$\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 可定义范数结构

$$\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|, \quad \infty - \text{范数},$$

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|, \quad 1 - \text{范数},$$

$$\|\mathbf{x}\|_2 = \left(\sum_{i=1}^n |x_i|^2 \right)^{1/2}, \quad 2 - \text{范数},$$

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}, \quad p - \text{范数}.$$



$p = \infty$



$p = 2$



$p = 1$




$0 < p < 1$



$p = 0$

曼哈顿距离




Hamming 距离

定义 (Hamming 距离)

Hamming 距离表示两个等长字符串在对应位置上不同字符的数目，汉明距离度量了通过替换字符的方式将字符串 x 变成 y 所需要的最小的替换次数。

Hamming 距离主要应用在通信编码领域上，用于制定可纠错的编码体系。在机器学习中，汉明距离也常常被用于作为一种距离的度量方式。



例

设 $\mathbf{u} = [-1, -9, 2]^T$, 则

$$\|\mathbf{u}\|_1 = |-1| + |-9| + |2| = 12,$$

$$\|\mathbf{u}\|_2 = \sqrt{|-1|^2 + |-9|^2 + |2|^2} = \sqrt{86},$$

$$\|\mathbf{u}\|_\infty = \max\{|-1|, |-9|, |2|\} = 9,$$

$$\|\mathbf{u}\|_5 = \left(|-1|^5 + |-9|^5 + |2|^5\right)^{1/5} = 9.0010.$$

Matlab 中用 norm 命令来求
向量的范数。

$$\mathbf{v} = [1, -7, 2]^T$$

```
>> norm(v, 1)
ans =
10.0000
>> norm(v, 'inf')
ans =
7
>> norm(v, 2)
ans =
7.3485
```

通过内积可定义 2-范数

$$\|x\|_2 = \sqrt{(x, x)}.$$

设 $x, y \in \mathbb{R}^n$, 其夹角为 α , 则

$$\cos \alpha = \frac{(x, y)}{\|x\|_2 \|y\|_2}.$$

由上面的公式亦可得出Cauchy-Schwarz 不等式, 且

$$(u, v) = \|u\|_2 \|v\|_2, \quad \alpha = 0,$$

$$(u, v) = -\|u\|_2 \|v\|_2, \quad \alpha = \pi.$$

说明二者平行时, 等号成立。

注记

内积可用于自然语言处理中的新闻分类。

稀疏性

设 $\mathbf{x} \in \mathbb{R}^n$ ，其0-范数为

$$\|\mathbf{x}\|_0 = \#(i | x_i \neq 0)$$

0-范数的大小反映了向量 \mathbf{x} 的稀疏程度，极小化0-范数可实现“压缩感知(compressed sensing)”和“稀疏编码(sparse coding)”。但是0-范数很难优化求解（NP难问题），而1-范数是0-范数的最优凸近似，且比0-范数要容易优化求解。所以1-范数也称为“稀疏规则算子”（Lasso regularization）。

$$\begin{array}{ccc} \min \|\mathbf{x}\|_0 & \begin{array}{c} \text{在一定条件下，以} \\ \text{概率1意义下等价} \end{array} & \min \|\mathbf{x}\|_1 \\ \text{s.t. } A\mathbf{x} = \mathbf{b} & \longleftrightarrow & \text{s.t. } A\mathbf{x} = \mathbf{b} \end{array}$$


稀疏性可以轻松实现特征选择和可解释性。

传统的数字信号采样定律就是有名的香农采样定理，又称那奎斯特采样定律：

定理 (Shannon采样定理)


为了不失真地恢复模拟信号，采样频率应该不小于模拟信号频谱中最高频率的2倍。

下图分别为在时域和空域上的数字化采集

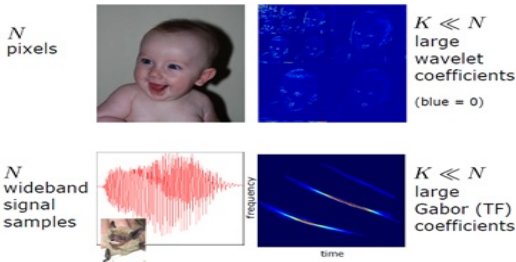


基于香农采样定理，目前传统图像信号采集设备的采样过程：


1、按照Nyquist采样率进行均匀采样，得到可以无失真恢复模拟信号的数字信号



信号存在冗余，即信号具有稀疏性：

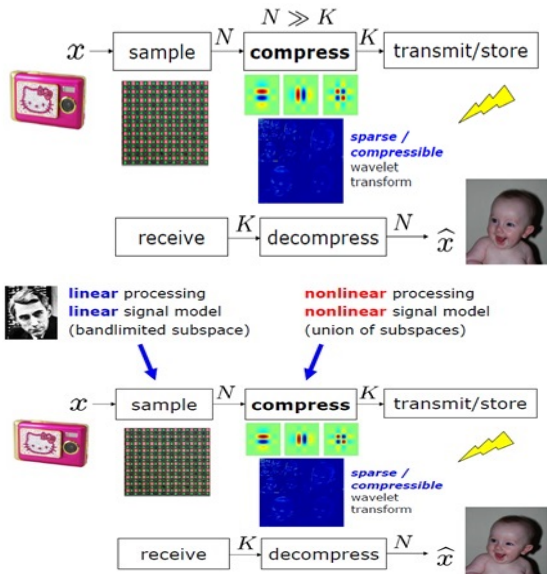


2、上述步骤得到的数字信号的数据量比较大，一方面不利于存储和传输，另一方面该数字信号本来存在很多冗余，可以对其进行进一步的压缩，于是就通过各种编码方法对数据进行有效的压缩：



相机的传感器通过将模拟信号（光）转换为数字信号，如 N pixel的图像信号，之后又通过压缩编码算法将 N pixel的图像信号转化为 K 个系数表示的数据，而 $K \ll N$ ，那么问题来了，为什么费了一番心思获得了 N 个采样值，却最后又通过复杂的编码算法将之压缩成 K 个数值？


基于以上的疑问，引出了压缩感知的概念：



压缩感知

顾名思义，就是感知压缩，直接获取压缩后的数据。即在采集的时候，直接采集有效的 M 个测量值，而非满足Nyquist采样定理的 N 个采样值（ $M \ll N$ ）。

$$K \approx \underline{M} \ll N$$



定义 (范数等价)

设 $\|\cdot\|_\alpha$ 和 $\|\cdot\|_\beta$ 是线性空间 V 的两个范数。若存在正的常数 C_1 和 C_2 , 使得

$$C_1\|u\|_\alpha \leq \|u\|_\beta \leq C_2\|u\|_\alpha, \quad \forall u \in S$$

则称范数 $\|\cdot\|_\alpha$ 和范数 $\|\cdot\|_\beta$ 等价。

定理

有限维空间中的任意两个范数等价。

$$\begin{aligned} \mathbf{x} \in \mathbb{R}^n \implies \quad & \|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \sqrt{n}\|\mathbf{x}\|_\infty, \\ & \|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_1 \leq n\|\mathbf{x}\|_\infty, \\ & \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1 \leq \sqrt{n}\|\mathbf{x}\|_2. \end{aligned}$$

对称阵的性质

如果 $A \in \mathbb{R}^{n \times n}$, $A^T = A$, 则称 A 为 **对称阵**。它有下列性质:

- ① A 的特征值均为实数, 且有 n 个线性无关的特征向量。
- ② A 对应于不同特征值的特征向量必正交。
- ③ 存在正交阵 Q 使得 $Q^{-1}AQ$ 为对角阵。

若还满足

$$(Ax, x) = x^T Ax \geq 0, \forall x \in \mathbb{R}^n,$$

则称 A 为 **半正定阵**(semidefinite matrix)。若上式等号只当 $x = 0$ 时成立, 则称 A 为 **正定阵**(definite matrix)。

实对称矩阵为正定阵的充要条件是它的所有特征值都是正数, 或者所有顺序主子式都是正定的。

定义 (矩阵范数)

$\mathbb{P}^{n \times n}$ 中的范数 $\|\cdot\|$: 是 $\mathbb{P}^{n \times n} \rightarrow \mathbb{R} : A \rightarrow \|A\|$ 的一个映射满足

- 正定性 $\|A\| \geq 0, \|A\| = 0 \Leftrightarrow A = 0$;
- 齐次性 $\|\alpha A\| = |\alpha| \|A\|$;
- 三角不等式 $\|A + B\| \leq \|A\| + \|B\|$;
- 次可乘性 (submultiplicative) $\|AB\| \leq \|A\| \|B\|$ 。

例 (Frobenius 范数)

$$A \in \mathbb{R}^{n \times n}, \quad \|A\|_F \stackrel{\text{def}}{=} \left(\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2}$$

$$\begin{aligned} \|AB\|_F^2 &= \sum_{i=1}^n \sum_{j=1}^n \left| \sum_{k=1}^n a_{ik} b_{kj} \right|^2 \\ &\leq \sum_{i=1}^n \sum_{j=1}^n \left(\sum_{k=1}^n |a_{ik}|^2 \sum_{k=1}^n |b_{kj}|^2 \right) \\ &= \left(\sum_{i=1}^n \sum_{k=1}^n |a_{ik}|^2 \right) \left(\sum_{j=1}^n \sum_{k=1}^n |b_{kj}|^2 \right) \\ &= \|A\|_F^2 \|B\|_F^2 \end{aligned}$$

定义 (相容性)

称矩阵范数与向量范数相容：若

$$\|A\mathbf{x}\| \leq \|A\| \cdot \|\mathbf{x}\|, \forall A \in \mathbb{P}^{n \times n}, \forall \mathbf{x} \in \mathbb{P}^n.$$

矩阵的F-范数与向量的2-范数相容：

$$\begin{aligned}\|A\mathbf{x}\|_2^2 &= \sum_{i=1}^n \left(\sum_{j=1}^n a_{ij}x_j \right)^2 \\ &\leq \sum_{i=1}^n \left(\sum_{j=1}^n |a_{ij}|^2 \sum_{j=1}^n x_j^2 \right) \\ &= \|A\|_F^2 \cdot \|\mathbf{x}\|_2^2\end{aligned}$$

$\|A\mathbf{x}\|$ 是 $\mathbf{x} \in \mathbb{R}^n$ 的连续函数, 因为

$$\begin{aligned}\|A(\mathbf{x} - \mathbf{y})\| &\leq C\|A(\mathbf{x} - \mathbf{y})\|_2 \\ &\leq C\|A\|_F\|\mathbf{x} - \mathbf{y}\|_2 \\ &\leq C\|A\|_F C'\|\mathbf{x} - \mathbf{y}\|\end{aligned}$$

设 $\|\cdot\|$ 是 \mathbb{R}^n 中任意给定的一向量范数, 集合

$$D = \{\mathbf{x} | \mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n, \|\mathbf{x}\| = 1\}$$

是一个有界闭集, 又 $\|A\mathbf{x}\|$ 是 \mathbf{x} 的连续函数, 则在 D 上可达极大值, 即存在 $\mathbf{x}_0 \in D$ 使得

$$\|A\mathbf{x}_0\| = \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\|.$$

对于任意 $\mathbf{x} \in \mathbb{R}^n$,

$$\frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} = \left\| A \frac{\mathbf{x}}{\|\mathbf{x}\|} \right\|, \quad \frac{\mathbf{x}}{\|\mathbf{x}\|} \in D$$

则 $\frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|}$ 在 $\mathbf{x} \in \mathbb{R}^n, \mathbf{x} \neq \mathbf{0}$ 上有最大值, 则可定义

定义 (从属范数)

设 $\|\cdot\|$ 是一个向量范数, 对 $\forall A \in \mathbb{R}^{n \times n}$,

$$\|A\| \stackrel{\text{def}}{=} \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} = \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\|$$

定义了 $\mathbb{R}^{n \times n}$ 上的一种范数, 称为从属于给定向量范数的矩阵范数, 简称从属范数 (subordinate matrix norm), 亦称算子范数 (operator norm)。

- 若 $\|A\| = 0$, 则 $A\mathbf{x} = 0, \forall \mathbf{x}$, 于是 $A = 0$;
- 显然 $\|\alpha A\| = |\alpha| \|A\|$;
- 显然 $\|A + B\| \leq \|A\| + \|B\|$;
- 因为 $\|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\|$, 从属范数是相容的。

$$\|AB\| = \max_{\|\mathbf{x}\|=1} \|AB\mathbf{x}\| \leq \max_{\|\mathbf{x}\|=1} \|A\| \|B\mathbf{x}\| = \|A\| \|B\|$$

- 单位矩阵 I 的任意从属范数为 1。
- 相容的范数未必是从属范数。如 $\|\cdot\|_F$ 与 $\|\cdot\|_2$ 相容, 但 $\|I\|_F = \sqrt{n}$ 。

设 $A \in \mathbb{P}^{n \times n}$, 则

$$\|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

$$\|A\|_2 = [\rho(A^T A)]^{1/2}$$

证明 $\|A\|_2 = [\rho(A^T A)]^{1/2}$

若 $A = A^T$, 则 $\rho(A) = \|A\|_2$, 这是否说明 $\rho(A)$ 是一个矩阵范数?

$$A = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$$

则 $\rho(A) = 0$, 但 $A \neq 0$ 。不满足正定性。

考虑 $B = A^T$, 则

$$\rho(A + B) = 1,$$

$$\rho(A) + \rho(B) = 0.$$

则

$$\rho(A) + \rho(B) < \rho(A + B),$$

三角不等式不成立。

Matlab 求矩阵范数

Matlab 中求矩阵范数的命令为 `norm`，除了求 1-, 2-, ∞ - 范数，还可求 Frobenius 范数。

$$A = \begin{bmatrix} -2 & 1 & -8 & 1 \\ 0 & -4 & -21 & 18 \\ -33 & 16 & -6 & 20 \\ 14 & -20 & -18 & 5 \\ 8 & -1 & 12 & 16 \end{bmatrix}$$

$$\|A\|_{\infty} = 33 + 16 + 6 + 20 = 75$$

$$\|A\|_1 = 8 + 21 + 6 + 18 + 12 = 65$$

```
>> norm(A,'inf')
```

```
ans =  
    75
```

```
>> norm(A,1)
```

```
ans =  
    65
```

```
>> norm(A,'fro')
```

```
ans =  
  63.5767
```

按照定义，可分别用 Matlab 中的 `eig` 和 `norm` 命令来求矩阵的 2-范数。

$$A = \begin{bmatrix} 1 & 13 & 5 & -9 \\ 12 & 55 & 5 & -6 \\ 18 & 90 & 1 & -1 \\ 3 & 0 & 2 & 3 \end{bmatrix}$$

```
>> E = eig(A'*A)
E =
    1.0e+004 *
         0.0000
         0.0021
         0.0131
         1.1802
>> sqrt(max(E))
ans =
    108.6373
>> norm(A,2)
ans =
    108.6373
>> norm(A) % default without
            second argument is the 2-norm
ans =
    108.6373
```


定理 (谱半径和范数)

设 $\|\cdot\|$ 为任一矩阵范数, 则 $\|A\| \geq \rho(A)$ 。

若取 $\mathbb{R}^{n \times n}$ 的范数为 $\|\cdot\|_\infty$, $\|\cdot\|_1$ 和 $\|\cdot\|_2$ 之一, 则有

$$\rho(A) \leq \|A\|.$$

定理

$\forall A \in \mathbb{R}^{n \times n}$ 及实数 $\epsilon > 0$, 存在一种从属的矩阵范数 $\|\cdot\|$, 使得

$$\|A\| \leq \rho(A) + \epsilon$$

定理

设 $\|\cdot\|$ 为 $\mathbb{R}^{n \times n}$ -从属范数。若 $\|B\| < 1$ ，则 $I + B$ 非奇异，且

$$\|(I + B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$

推论 (摄动引理)

设 $A, C \in \mathbb{R}^{n \times n}$, 若 A^{-1} 存在, $\|A^{-1}\|\|A - C\| < 1$, 则

$$\|C^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|A - C\|}$$

定义 (实初等矩阵)

设 $u, v \in \mathbb{R}^n$, $\sigma \in \mathbb{R}$, 称

$$E(u, v; \sigma) \stackrel{\text{def}}{=} I - \sigma uv^T$$

为实初等矩阵。

设 $\mathbf{u} = (u_1, u_2, \dots, u_n)^T$, $\mathbf{v} = (v_1, v_2, \dots, v_n)^T$, 则

$$\begin{aligned}\mathbf{u}\mathbf{v}^T &= \begin{pmatrix} u_1 \\ u_2 \\ \dots \\ u_n \end{pmatrix} \begin{pmatrix} v_1 & v_2 & \dots & v_n \end{pmatrix} \\ &= \begin{pmatrix} u_1 v_1 & u_1 v_2 & \dots & u_1 v_n \\ u_2 v_1 & u_2 v_2 & \dots & u_2 v_n \\ \dots & \dots & \dots & \dots \\ u_n v_1 & u_n v_2 & \dots & u_n v_n \end{pmatrix}\end{aligned}$$

引理

初等矩阵若可逆，其逆也是（同类型）初等矩阵。

证明： 因为

$$\begin{aligned}E(\mathbf{u}, \mathbf{v}; \sigma)E(\mathbf{u}, \mathbf{v}; \tau) &= (\mathbf{I} - \sigma \mathbf{u} \mathbf{v}^T)(\mathbf{I} - \tau \mathbf{u} \mathbf{v}^T) \\&= \mathbf{I} - (\sigma + \tau - \sigma \tau (\mathbf{v}^T \mathbf{u})) \mathbf{u} \mathbf{v}^T,\end{aligned}$$

若令

$$\sigma + \tau - \sigma \tau (\mathbf{v}^T \mathbf{u}) = 0,$$

即

$$\tau = \frac{\sigma}{\sigma \mathbf{v}^T \mathbf{u} - 1},$$

则

$$E(\mathbf{u}, \mathbf{v}; \sigma)^{-1} = E(\mathbf{u}, \mathbf{v}; \tau).$$

- 若 $\mathbf{v}^T \mathbf{u} = 0$, 即 \mathbf{u} 与 \mathbf{v} 垂直, 则有 $\tau = -\sigma$,

$$E(\mathbf{u}, \mathbf{v}; \sigma)^{-1} = E(\mathbf{u}, \mathbf{v}; -\sigma).$$

- $\det E(\mathbf{u}, \mathbf{v}; \sigma) = 1 - \sigma \mathbf{v}^T \mathbf{u}$ 。原因在于 $\mathbf{u}\mathbf{v}^T$ 的所有特征值为 0 和 $\mathbf{v}^T \mathbf{u}$ 。

- 初等排列阵 $\mathbf{I}_{ij} \stackrel{\text{def}}{=} E(\mathbf{e}_i - \mathbf{e}_j, \mathbf{e}_i - \mathbf{e}_j; 1)$ 。

初等排列阵 \mathbf{I}_{ij} 左乘一个矩阵表示将该矩阵的第 i 行和第 j 行互换。初等排列阵 \mathbf{I}_{ij} 右乘一个矩阵则表示将该矩阵的第 i 列和第 j 列互换。

$$\mathbf{I}_{ij}^{-1} = \mathbf{I}_{ij}。$$

- $E(\mathbf{e}_j, \mathbf{e}_i; -\alpha) = \mathbf{I} + \alpha \mathbf{e}_j \mathbf{e}_i^T$

左乘一个矩阵表示将该矩阵的第 i 行的 α 倍加到第 j 行上去。

$E(\mathbf{e}_j, \mathbf{e}_i; -\alpha) = \mathbf{I} + \alpha \mathbf{e}_j \mathbf{e}_i^T$ 右乘一个矩阵表示将该矩阵的第 j 列的 α 倍加到第 i 列上去。

初等下三角阵

若记 $\mathbf{l}_j = (0, \dots, 0, l_{j+1,j}, \dots, l_{n,j})^T$, 其前 j 个分量为零。令

$$L_j(\mathbf{l}_j) = E(\mathbf{l}_j, \mathbf{e}_j; -1) = \mathbf{I} + \mathbf{l}_j \mathbf{e}_j^T = \begin{pmatrix} 1 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \vdots & \vdots \\ 0 & \cdots & 1 & 0 & \cdots & 0 \\ 0 & \cdots & l_{j+1,j} & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & l_{n,j} & 0 & \cdots & 1 \end{pmatrix}$$

注记

$L_j(\mathbf{l}_j)$ 左乘一个矩阵表示将 j 行的 $l_{k,j}$ 倍加到 k 行上去, k 从 $j+1$ 行到 n 行。

由

$$\mathbf{e}_j^T \mathbf{l}_j = 0 \Rightarrow L_j(\mathbf{l}_j)^{-1} = L_j(-\mathbf{l}_j).$$

当 $i \leq j$ 时,

$$\begin{aligned} L_i(l_i)L_j(l_j) &= (I + l_i \mathbf{e}_i^T)(I + l_j \mathbf{e}_j^T) \\ &= I + l_i \mathbf{e}_i^T + l_j \mathbf{e}_j^T \end{aligned}$$

因而一个（单位）下三角阵可以写成

$$L = L_1(l_1)L_2(l_2) \cdots L_{n-1}(l_{n-1}).$$

定义

设 $A \in \mathbb{R}^{n \times n}$, 若存在排列矩阵 $P \in \mathbb{R}^{n \times n}$ 使得

$$P^T A P = \begin{bmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{bmatrix}$$

如果 A_{11}, A_{22} 为方阵, 则称 A 为 **可约矩阵** (*reducible matrix*); 否则, 称 A **不可约** (*irreducible*)。

注记 (判别准则)

矩阵 $A \in \mathbb{R}^{n \times n}$ 是可约的, 若它的指标 1 到 n 可被分成两个互不相交的非空集合 $S = \{i_1, i_2, \dots, i_\alpha\}$ 和 $T = \{j_1, j_2, \dots, j_\beta\}$, $\alpha + \beta = n$, 使得

$$a_{i_p j_q} = 0, \quad 1 \leq p \leq \alpha, \quad 1 \leq q \leq \beta.$$

例 (可约矩阵)

$$A = \begin{bmatrix} 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 2 & 3 \\ 8 & 0 & 0 & 0 & 9 \\ 5 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 12 & 0 \end{bmatrix},$$

$$S = \{1, 3, 4, 5\}, \quad T = \{2\},$$

且

$$a_{12} = a_{32} = a_{42} = a_{52} = 0$$

因此 A 可约。

若 A 是可约阵, 因为 $P^T = P^{-1}$, 方程组 $A\mathbf{x} = \mathbf{b}$ 可写为

$$P^T A P \mathbf{y} = P^T \mathbf{b},$$

$$\mathbf{y} = P^T \mathbf{x}.$$

方程组有分块形式

$$\begin{bmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{bmatrix} \begin{bmatrix} \mathbf{y}_1 \\ \mathbf{y}_2 \end{bmatrix} = \begin{bmatrix} \bar{\mathbf{b}}_1 \\ \bar{\mathbf{b}}_2 \end{bmatrix}$$

注记

若矩阵可约, 则原方程可以化为先解一个低阶方程组 $A_{22}\mathbf{y}_2 = \bar{\mathbf{b}}_2$, 再解 $A_{11}\mathbf{y}_1 = \bar{\mathbf{b}}_1 - A_{12}\mathbf{y}_2$ 。